

生成式人工智慧與異質平台整合應用

演講者：勤益科大 資訊工程系 權振坤 教授

演講日期: 2025 / 11/ 11

1. 摘要 (Extended Abstract)

近年來，生成式人工智慧（Generative Artificial Intelligence, GAI）迅速成為工業界與學術界的重要研究方向。其應用範圍從內容創作、語言理解、影像生成到智慧製造決策支援皆已展現深厚影響力。本報告將從生成式模型的技術原理、GAN 與 Transformer 架構、模型訓練流程、硬體與算力需求、生產排程（APS）整合、可信任 AI (Trustworthy AI)，到產業導入的挑戰等議題，進行詳盡分析。

本研究發現，生成式 AI 雖具備高度自動化、推論能力強、跨模態整合等優勢，但仍面臨資料需求巨大、推論不具穩定性、企業導入成本高昂等困境。未來發展應朝向提升模型可信度、建立異質平台整合機制、加強資料治理、並將 GAI 定位為人機協作（Human-AI Collaboration）的智慧工具，而非直接替代決策者。

2. 前言 (Introduction)

生成式人工智慧（GAI）最早源於隱變量模型（Latent Variable Model）與深度學習的結合，其核心能力是「從資料中學到分布，再生成新的資料樣本」。自 GAN 與 Transformer 出現後，GAI 被廣泛應用於影像、語言、音樂、影片、工業製造等場域 [1]。

然而，GAI 在實務導入上仍面臨多項挑戰，包括模型不具絕對準確性、對大量資料的依賴、需人員審核才能避免錯誤，以及模型在突發情況下的表現不穩定等問題。相關研究也指出，生成式模型在決策場景中必須搭配人工介入，以維持可靠性與安全性[2]。因此，GAI 在目前階段更適合作為人類決策的輔助工具，而非完全取代者。本報告旨在針對技術與應用層面提供更深入的分析，以供後續研究與產業導入策略之參考。

3. 生成式模型技術全面解析

3.1 生成式模型的分類

生成式模型的核心目標是從既有資料中學習其深層的統計結構，並據此生成新的資料，而這些資料在外觀或語意上應與原始資料相似。生成式模型的設計方法大致可分為「顯式密度模型(Explicit Density Model)」與「隱式密度模型(Implicit Density Model)」兩大方向。顯式密度模型的特點在於試圖建立資料的機率密度函數，模型會直接或間接估計資料的出現機率，因此這類方法通常具有較完整的數學基礎與可解釋性。然而，當資料的維度極高或分布複雜時，顯式建模可能變得困難，因此常需使用近似方法，如變分推論或其他數值技巧，使模型能在不精確求解下仍保持穩定運作[3]。

與此相對，隱式密度模型則完全不需對資料的機率分布進行明確描述，而是透過生成樣本的方式「間接」學習資料的分布關係。這類模型更接近人類從觀察

中模仿的方式：不需理解每張圖像的數學分布，只需產生類似的結果即可。因此，它們在影像、語音、影片等高維資料的生成中特別有優勢。這兩大類模型的存在，展示了生成式 AI 在設計理念上的不同取向：前者著重於數學可解性與模型結構，另一者則強調生成能力與靈活度，兩者共同構成當前生成式 AI 的基礎技術背景。

3.2 GAN 之運作原理

生成器的任務是將隨機噪聲映射成看似真實的資料，而判別器的任務則是區分輸入資料是真實資料還是生成器的產物。兩者透過反覆競爭，形成一種零和博奕，使得生成器生成資料的能力不斷提升。GAN 的特殊之處在於，它並不需要了解資料的機率分布，也不需進行複雜的密度估計，只需透過「以假亂真」的方式來逼近真實資料的特性。正因如此，GAN 特別適合用於影像生成、風格轉換、資料擴增、影像修補等應用領域[4]。

而 GAN 的主要優勢，包括它能在資料不足時產生不存在的資料，或作為補充既有資料集的工具。因此，在真實世界資料難以蒐集、資料不平衡嚴重、或需要模擬新環境的場景中，GAN 能夠有效提升資料的豐富度與模型整體性能。這使得 GAN 成為許多研究領域的重要技術，例如醫療影像的補齊、製造業瑕疵偵測的資料擴增、甚至深偽影像（Deepfake）技術的生成。

3.3 Transformer 與大型語言模型（LLM）架構

除了 GAN 之外，近年來生成式人工智慧最具突破性的技術莫過於 Transformer 與其衍生的大型語言模型（LLM）[5]。簡報中以 ChatGPT 4.0 為例，強調 Transformer 已經成為現代自然語言處理與語言生成的主流架構。Transformer 最核心的特點是「自注意力機制（Self-Attention）」，它能讓模型在處理語句時同時考慮所有字詞與其他字詞之間的關係，不會受到傳統序列模型（如 RNN、LSTM）容易遺失長距資訊的限制。由於其運算可以高度平行化，Transformer 能在巨量資料集上快速訓練，使模型能理解語言的語意結構、邏輯關係與跨句脈絡。

GPT 系列模型訓練方式的三個階段：首先，模型透過監督式學習（Supervised Fine-Tuning）從示範資料中學習人類回答問題的方式；接著，利用比較資料讓模型學會哪些回答比較好、哪些比較差，從而建立「獎勵模型」；最後，再利用「人類回饋強化學習（Reinforcement Learning from Human Feedback, RLHF）」進行策略優化，使模型的輸出逐漸符合人類期望的互動方式。

透過這樣的訓練流程，Transformer 模型不僅能生成語法正確的文字，更能生成具有邏輯性、連貫性，甚至風格一致的內容。這也是為什麼現代 LLM 能廣泛應用於客服回覆、內容生成、語意理解、程式碼生成等領域[6]。整體而言，Transformer 的成功不只是架構上的創新，更是因為它結合了大規模資料、精密的訓練策略，以及對人類偏好的深度學習，使其成為生成式 AI 技術中不可或缺的核心。

4. 生成式 AI 在產業中的應用與發展

生成式人工智慧的快速演進，正在重新塑造不同產業的運作方式。這類模型能理解資料中的深層結構，並進一步生成新內容，使得它在製造、媒體、金融與服務業等領域都展現高度應用價值。在製造業環境中，生產排程（APS）是最能體現生成式 AI 實用性的領域之一[7]，傳統的排程流程往往依賴人工經驗與大量查詢工作，例如工時計算、物料備貨狀況確認、設備切換時間推估等，這些步驟既耗時，也容易受到人為因素的影響。當生成式模型被導入後，系統能透過過去的生產紀錄與設備運作資訊，推估最佳排程方案，並自動產生工時估算與交期建議，使整體流程更加精準且具效率[8]。

生成式 AI 的應用並不限於製造領域，它也深刻影響內容與創意產業。其影像生成、音樂作曲與視覺設計能力，使創作者能快速產出生動的草圖與初步作品，進而縮短開發流程。例如，一段影片的概念畫面過去需要設計師花費大量時間來產生，而如今 AI 可以在極短時間內生成多種視覺風格[9]，讓創作者得以專注於構思層面的創意延伸。在視覺設計領域，AI 也協助建立多樣化的圖片與素材，提高整體產出的效率與豐富度[10]。

在企業導入實務中，生成式 AI 的整合涉及多項要素，包括運算平台、資料庫建構與模型調校能力。AI 若要具備產業實用性，其訓練資料必須涵蓋組織的背景知識、流程紀錄及領域專業資訊。接著，透過具備運算能力的訓練平台，才能讓模型有效吸收資料並形成具領域特性的理解能力。最後則是調校與優化，需要專業人員根據企業需求持續調整模型，使其輸出結果貼近實務需求。上述架構不僅顯示生成式 AI 的多層次導入特性，也說明企業在使用 AI 時所面對的整體性工程挑戰[11]。

5. 生成式 AI 的運算成本與硬體需求

生成式人工智慧的能力背後，需要大量運算資源的支撐。大型生成式模型的訓練通常需要龐大的資料集與高效能硬體，因此其成本往往超出一般企業的負擔範圍。以近年來被廣泛討論的 GPT 系列模型為例，其規模隨版本演進而迅速成長。早期的小型模型可在中等等級的 GPU 上完成訓練，所需資料量也較為有限。然而，進入更高階版本後，模型參數數量呈指數成長，訓練時需要的 GPU 張數、運算時間以及資料量也大幅增加[12]。

目前常見的高效能 GPU 包括 P100、A100 與 H100 等等，它們分別代表不同時期的運算能力水準。P100 主要適用於較小規模的模型，其運算能力雖足以支援深度學習，但對於大型生成模型而言已顯不足。A100 則具備更高的記憶體頻寬與矩陣運算能力，成為大多數先進 AI 模型訓練的主要選擇。而 H100 作為最新一代的資料中心 GPU，在效能上相較過往大幅提升，使其成為目前訓練大型生成式模型的首選硬體。然而，這些 GPU 的成本極高，且在大量部署時通常需要配合完整伺服器架構與冷卻環境，導致整體訓練成本相當可觀。

不僅硬體本身昂貴，大規模模型的訓練時間亦十分長。以大型語言模型為例，完整的訓練過程往往需要數週甚至數月，期間需耗費大量電力與雲端運算資源，

加上資料蒐集、清洗與架構優化等前置作業，使得總成本更為增加[13]。在這樣的背景下，許多企業選擇不自行訓練大型模型，而改用雲端供應商提供的推論服務或 API，藉此降低硬體建置成本並加快導入速度。此趨勢反映出生成式 AI 的商業模式逐漸從「自行訓練」轉向「雲端使用」，進一步提升了中小企業採用的可能性[14]。

6. 生成式 AI 的挑戰與限制

儘管生成式人工智慧展現強大能力，但在實務應用上仍需面對多重挑戰。首先，生成式模型的輸出具有不確定性，即使模型能力再強，也無法保證每次產生的內容都完全正確或符合預期。在需要高準確度的領域，例如生產排程、醫療分析或財務預測中，這類不確定性可能導致錯誤決策，因此必須在流程中加入人工審核與風險控管。

另一方面，資料的品質對模型性能有著決定性的影響。因此，生成式 AI 要具備可靠的輸出能力，需要大量多元且高品質的資料。然而在企業環境中，資料常存在格式不一致、紀錄不完整或缺乏標註等問題，使得資料清理與整理過程需投入大量成本。資料治理若不完善，即使使用先進的模型，也可能因為輸入資料品質不佳而導致結果偏差。

此外，生成式 AI 的導入也牽涉到倫理與可信度的議題。模型可能產生偏見、錯誤資訊或不當內容，若是缺乏完善的監管機制，則會影響企業運作甚至造成社會風險。因此，建立可信任 AI 的框架，包括公平性、透明度、安全性與可解釋性等面向，已成為企業導入 AI 必須謹慎面對的一項重要課題。

最後，即便生成式 AI 能提升效率，它仍無法完全取代人類的判斷能力。當面臨突發事件、複雜決策或跨領域整合時，AI 輸出結果仍可能不足或產生偏差，甚至在某些情況下提供完全不正確的回應。因此，人類角色在整個流程中依然扮演著監督者、調整者和最終決策者的功能，使 AI 成為支持工具而非完全替代者。

7. 結論

生成式人工智慧已成為推動產業轉型的重要技術，其能力涵蓋資料理解、內容生成與決策輔助，對各類產業產生深遠影響。無論是在製造業的排程管理、創意產業的內容生成，或是企業流程的自動化整合，生成式 AI 都展現出卓越價值。然而，這項技術的落地應用並非單純引入模型即可達成，而是需要結合資料治理、運算平台、模型調校與人類監督等多層次努力。

另一方面，生成式 AI 的導入也伴隨重大挑戰，包括巨大的硬體成本、資料整備的複雜性、模型輸出的不確定性與可信任性問題等。這些因素提醒企業在採用 AI 時，應以務實態度規劃導入步驟，同時建立健全的審核與監控流程，以確保科技能真正為組織創造效益。

未來，隨著硬體技術持續演進、模型架構不斷優化以及雲端服務的普及，生成式 AI 將更加容易被不同規模的企業接受。結合人類專業判斷與 AI 的智能能力，將使組織在效率、決策品質與創新能力上獲得更全面的提升，並為數位化

與智慧化發展奠定更堅實的基礎。

參考文獻

- [1] T. B. Brown, B. Mann, N. Ryder et al., “Language models are few-shot learners,” in *Advances in Neural Information Processing Systems*, 2020.
- [2] European Commission, *Ethics Guidelines for Trustworthy AI*. Luxembourg: Publications Office of the European Union, 2021.
- [3] D. P. Kingma and M. Welling, “Auto-encoding variational Bayes,” arXiv preprint arXiv:1312.6114, 2014.
- [4] Goodfellow, J. Pouget-Abadie, M. Mirza et al., “Generative adversarial nets,” in *Advances in Neural Information Processing Systems*, 2014.
- [5] A. Vaswani, N. Shazeer, N. Parmar et al., “Attention is all you need,” in *Advances in Neural Information Processing Systems*, 2017.
- [6] L. Ouyang, J. Wu, X. Jiang et al., “Training language models to follow instructions with human feedback,” arXiv preprint arXiv:2203.02155, 2022.
- [7] J. Lee, B. Bagheri, and H.-A. Kao, “A cyber–physical systems architecture for Industry 4.0-based manufacturing systems,” *Manufacturing Letters*, vol. 3, pp. 18–23, 2015.
- [8] L. Monostori, “Cyber-physical production systems: Roots, expectations and R&D challenges,” *Procedia CIRP*, vol. 17, pp. 9–13, 2014.
- [9] A. Ramesh, M. Pavlov, G. Goh et al., “Zero-shot text-to-image generation,” arXiv preprint arXiv:2102.12092, 2021.
- [10] T. Karras, S. Laine, and T. Aila, “A style-based generator architecture for generative adversarial networks,” in *Proc. IEEE/CVF Conf. Computer Vision and Pattern Recognition (CVPR)*, 2019.
- [11] S. Garcia, J. Luengo, and F. Herrera, “Automated machine learning for industry: Challenges and opportunities,” *Information Fusion*, vol. 91, pp. 1–17, 2023.
- [12] OpenAI, *GPT-4 Technical Report*, OpenAI, 2023.
- [13] R. Bommasani, D. Hudson, E. Adeli et al., “On the opportunities and risks of foundation models,” Stanford Institute for Human-Centered Artificial Intelligence, 2021.
- [14] X. Zhang, J. Li, and Z. Yu, “Cloud-based deployment strategies for large language models in enterprise environments,” *Journal of Cloud Computing*, vol. 12, no. 1, pp. 1–18, 2023.